

Failure Analysis of a Milling Machine with Synthetic Data in a Real-Time Architecture

Autor: Ítalo Vinícius Pereira Guimarães

Universidade: Universidade de Brasília



Introdução

○ Contexto:

- Importância das fresadoras na indústria moderna.
- Riscos associados a falhas mecânicas.

○ Problema:

- Métodos tradicionais de manutenção são limitados.
- Necessidade de detecção de falhas em tempo real.

○ Solução Proposta:

- Uso de aprendizado de máquina e arquitetura Lambda para detecção de falhas.

Objetivo

- Desenvolver um sistema escalável e robusto para detecção de falhas em fresadoras.
- Integrar dados sintéticos e modelos avançados de machine learning.
- Combinar processamento em tempo real para análises e enriquecimento dos dados.

Revisão de literatura

○ **Manutenção Preditiva:**

- Comparação com manutenção reativa e preventiva.

○ **Machine Learning na Indústria:**

- Modelos populares: XGBoost, CatBoost, Redes Neurais.
- Desafios: desbalanceamento de classes, integração com sistemas legados.

○ **Arquitetura Lambda:**

- Processamento em tempo real e em lote.
- Aplicações bem-sucedidas em diagnósticos industriais.

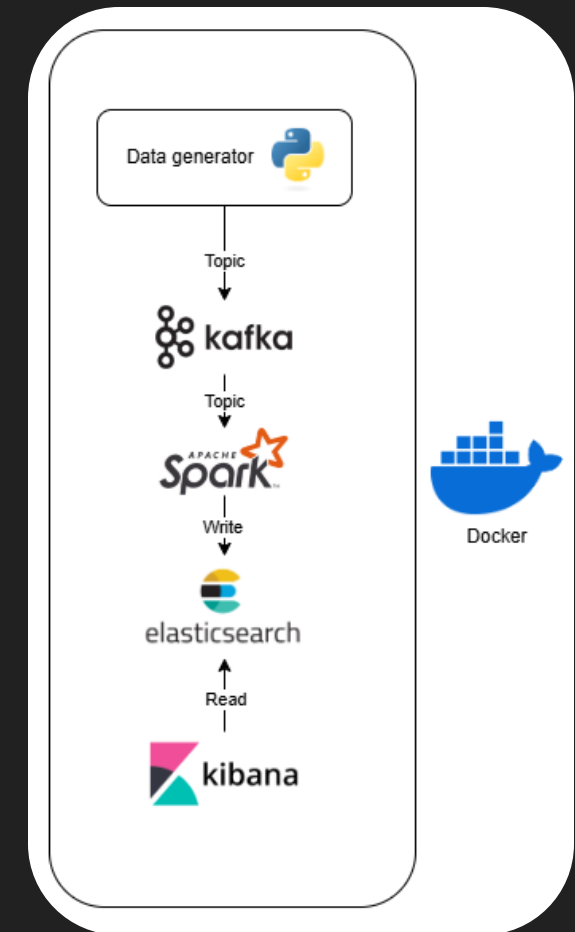
Metodologia - Arquitetura

Componentes da Arquitetura Lambda:

- Gerador de Dados.
- Kafka (broker de mensagens).
- Spark Streaming (camada de velocidade).
- Elasticsearch e Kibana (armazenamento e visualização).

Fluxo de Dados:

- Dados gerados simulam sensores industriais.
- Processamento em Spark para detecção de falhas em tempo real.



Metodologia - Modelo

○ Modelos Treinados:

- XGBoost e CatBoost para predição de falhas críticas.

○ Labels Previstos:

- *Machine Failure, HDF, PWF, OSF.*
- Exclusão de *TWF* e *RNF* por baixa performance.

○ Pipeline de Treinamento:

- Engenharia de características (ex.: *Power, Power Wear*).
- Técnicas contra desbalanceamento (oversampling).
- Avaliação usando métricas como F1-Score e ROC-AUC.

Resultados

- **Performance dos Modelos:**

- Alta acurácia para *Machine Failure*, *HDF*, *PWF*, e *OSF*.
- Baixa performance para *TWF* e *RNF* devido ao desbalanceamento.

- **Métricas:**

- XGBoost: Acurácia média de 98%.
- CatBoost: Leve vantagem em recall para falhas críticas.

Desafios e limitações

- **Limitações:**

- Dados sintéticos vs. dados reais.
- Desbalanceamento extremo em classes raras.
- Escalabilidade para múltiplas máquinas industriais.

- **Soluções Futuras:**

- Modelos dinâmicos com aprendizado contínuo.
- Feedback contínuo para re-treinamento do modelo.

Conclusão

- **Contribuições:**

- Integração de machine learning com arquitetura Lambda.
- Detecção eficaz de falhas críticas em fresadoras.

- **Impacto:**

- Redução de custos e maior eficiência operacional.

- **Aplicações Futuras:**

- Escalabilidade para outros equipamentos industriais.
- Adaptação para condições reais e ambientes dinâmicos.


Trabalhos futuros

- Tratamento avançado de desbalanceamento.
- Integração com sistemas legados.
- Uso de técnicas de explainable AI (XAI).
- Análise de custos e sustentabilidade.


Aplicação no mundo real



Necessidade de modelos flexíveis e adaptáveis.



Feedback contínuo para re-treinamento.



Integração para times de dados e MLOps.

Perguntas?

